Propuesta de Evolución Gradual del Algoritmo Sargon

Aprendizaje de pesos, valor contextual de piezas y profundidad adaptativa

Nota de trabajo

29 de septiembre de 2026

Resumen

Esta nota propone una evolución incremental y controlable del algoritmo Sargon mediante aprendizaje a partir de partidas propias y partidas expertas en formato PGN. La idea rectora es preservar en todo momento una línea base estable: cuando no existe experiencia acumulada, el comportamiento del sistema debe coincidir exactamente con el Sargon clásico. A partir de esa base se introducen, de manera independiente y medible, tres mecanismos de aprendizaje: ajuste de los pesos de la función de valor, estimación contextual del valor de las piezas y profundidad adaptativa de búsqueda. Se propone además un esquema de autoridad de las fuentes de experiencia, un mecanismo de confianza gradual y una estrategia experimental que permita verificar el aporte de cada componente antes de avanzar hacia modelos más complejos.

1. Principio rector

El objetivo no es reemplazar Sargon por una arquitectura completamente distinta, sino construir una evolución progresiva del algoritmo existente.

La condición fundamental es:

$$\boxed{\text{sin experiencia} \Rightarrow \text{Sargon clásico}}$$

y, a medida que se acumula evidencia:

$$\boxed{\text{Sargon adaptativo} = \text{Sargon clásico} + \text{correcciones aprendidas}}$$

En ausencia de experiencia:

$$\Delta w = 0, \qquad \Delta v = 0, \qquad \Delta d = 0,$$

por lo que:

$$\boxed{Sargon_{\text{adaptativo}} = Sargon_{\text{clásico}}}$$

Esta propiedad debe verificarse mediante pruebas automáticas.

2. Arquitectura conceptual

Se propone separar el aprendizaje en tres módulos independientes:

$$\boxed{\text{Sargon adaptativo} = \text{Valor aprendido} + \text{Material contextual} + \text{Profundidad adaptativa}}$$

3. Módulo I: aprendizaje de pesos de la función de valor

Supóngase que la evaluación clásica de Sargon puede escribirse como:

$$V_S(s) = \sum_{i=1}^{n} w_i^{(0)} f_i(s),$$

donde $f_i(s)$ son características posicionales y $w_i^{(0)}$ los pesos originales.

Entre las características pueden encontrarse material, movilidad, control del centro, estructura de peones, seguridad del rey, desarrollo, espacio, actividad e iniciativa.

La evolución propuesta consiste en mantener el peso original y aprender sólo una corrección:

$$w_i = w_i^{(0)} + \Delta w_i.$$

Inicialmente:

$$\Delta w_i = 0.$$

La evaluación efectiva será:

$$V(s) = \sum_{i} \left(w_i^{(0)} + \Delta w_i \right) f_i(s).$$

Esto mantiene el modelo interpretable.

Factor	Sargon clásico	Valor aprendido
Material	1.00	0.98
Movilidad	0.12	0.19
Seguridad del rey	0.30	0.44
Peón aislado	-0.18	-0.15

4. Módulo II: valor contextual de las piezas

Se mantienen como referencia los valores base:

$$P = 1, \qquad N = 3, \qquad B = 3, \qquad R = 5, \qquad Q = 9.$$

Para cada tipo de pieza:

$$v_p(s) = v_p^{(0)} + \Delta v_p(s).$$

Por ejemplo, para un caballo:

$$v_N(s) = 3 + \alpha_1 C(s) + \alpha_2 M(s) + \alpha_3 O(s) + \alpha_4 F(s),$$

donde C mide centralización, M movilidad, O calidad de un puesto avanzado y F fase de la partida.

Así, una pieza puede adquirir un valor efectivo dependiente del contexto. Sin experiencia:

$$\Delta v_p(s) = 0.$$

El mismo principio puede aplicarse a pareja de alfiles, torres en columnas abiertas, dama activa, peones pasados y piezas menores en finales.

5. Módulo III: profundidad adaptativa

Sea d_0 la profundidad base de Sargon. La profundidad efectiva se define como:

$$d(s) = d_0 + \Delta d(s).$$

Inicialmente:

$$\Delta d(s) = 0.$$

Con experiencia, el sistema puede aprender que algunas posiciones merecen más análisis y otras menos.

Tipo de posición	Profundidad sugerida
Tranquila	3
Normal	4
Compleja	5
Crítica o táctica	7

Debe imponerse:

$$d_{\text{mín}} \leq d(s) \leq d_{\text{máx}}.$$

6. Fuentes de experiencia

Se consideran dos fuentes principales.

6.1. Partidas propias

Las partidas jugadas por el propio motor son válidas, pero su autoridad debe ser moderada:

$$\omega_{\text{self}} = 1.$$

6.2. Partidas expertas en PGN

Las partidas de grandes maestros, motores fuertes o corpus validados reciben mayor autoridad:

$$\omega_{\text{expert}} > \omega_{\text{self}}.$$

Por ejemplo:

$$\omega_{\text{expert}} = 5.$$

Una actualización genérica puede escribirse como:

$$\Delta\theta = \alpha\, \omega_{\text{source}}\, \delta\, \nabla_\theta V.$$

La procedencia debe conservarse:

```
source=self
source=pgn
source=master
source=engine
```

y opcionalmente:

```
authority=1.0
authority=5.0
authority=10.0
```

7. Aprendizaje desde PGN experto

Sea una posición s donde el experto elige:

$$a^*.$$

Sean:

$$a_1, \ldots, a_n$$

las jugadas legales.

El PGN aporta evidencia de preferencia:

$$Q(s, a^*) \gtrsim Q(s, a_j), \qquad \forall j.$$

No se asume que a^* sea la única jugada correcta, sino una observación de alta autoridad.

Puede usarse una pérdida de ranking:

$$L = \sum_{a \neq a^*} \text{máx}\left(0,\, m - [V(T(s, a^*)) - V(T(s, a))]\right),$$

donde m es un margen mínimo.

8. Aprendizaje desde partidas propias

El resultado final es:

$$z = \begin{cases} +1 & \text{victoria,} \\ 0 & \text{tablas,} \\ -1 & \text{derrota.} \end{cases}$$

Puede aplicarse TD:

$$\delta_t = r_{t+1} + \gamma V(s_{t+1}) - V(s_t).$$

Con trazas de elegibilidad:

$$e_t = \gamma \lambda e_{t-1} + \nabla V(s_t),$$

y:

$$\theta_{t+1} = \theta_t + \alpha \delta_t e_t.$$

Conviene que:

$$\alpha_{\text{self}} < \alpha_{\text{expert}}.$$

9. Qué debe aprender cada módulo

Pesos posicionales

Los PGN expertos son especialmente útiles porque proporcionan gran cantidad de decisiones:

$$a^* \succ a.$$

Valor contextual de piezas

Debe concentrarse en posiciones informativas: intercambios, sacrificios, simplificaciones, finales, cambios de piezas menores, cambios de dama y entregas de calidad.

Profundidad adaptativa

El PGN no contiene la profundidad mental del experto, pero puede construirse una señal propia del motor.

Para cada posición experta se ejecuta Sargon a profundidades crecientes:

$$d = 1, 2, \ldots, D.$$

Se define:

$$d^* = \text{mín}\left\{d : a_{\text{Sargon}}(s, d) = a_{\text{expert}}\right\}.$$

Así se genera un dataset:

$$(s, d^*).$$

Este d^* no representa cuánto calculó el maestro, sino cuánto necesita Sargon para reproducir su decisión.

10. Confianza gradual

Cada parámetro aprendido debe asociarse con:

$$(\text{valor aprendido}, N, c),$$

donde N es la evidencia acumulada y c la confianza.

La integración puede formularse como:

$$w_i^{\text{eff}} = (1 - c_i)w_i^{(0)} + c_i w_i^{(L)},$$

con:

$$0 \leq c_i \leq 1.$$

Una función sencilla:

$$c(N) = \frac{N}{N + K}.$$

Por ejemplo, con $K = 1000$:

$$N = 0 \Rightarrow c = 0, \qquad N = 1000 \Rightarrow c = 0{,}5, \qquad N = 9000 \Rightarrow c = 0{,}9.$$

La evidencia experta puede incrementar el número efectivo:

$$N_{\text{efectivo}} = \omega_{\text{source}} N.$$

11. Evolución por niveles

Nivel 0: Sargon clásico

$$\Delta w = 0, \qquad \Delta v = 0, \qquad \Delta d = 0.$$

Nivel 1: aprendizaje de pesos

Se habilita únicamente:

$$w_i^{(0)} \to w_i.$$

Nivel 2: valor contextual de piezas

Se habilita:

$$v_p(s) = v_p^{(0)} + \Delta v_p(s).$$

Nivel 3: profundidad adaptativa

Se incorpora:

$$d(s) = d_0 + \Delta d(s).$$

Esta etapa debe introducirse sólo después de demostrar que los niveles anteriores son estables.

12. Por qué no comenzar con una red neuronal grande

En las primeras fases conviene utilizar modelos pequeños e interpretables.

Para los pesos:

$$\Delta w_i$$

puede ser un conjunto directo de parámetros.

Para material contextual:

$$\Delta v_p(s) = \beta^\top g_p(s).$$

Para profundidad:

$$\Delta d(s) = \text{round}\left(\eta^\top h(s)\right).$$

Sólo si una aproximación lineal muestra una limitación objetiva debería reemplazarse por una red neuronal pequeña.

13. Persistencia

Se propone una base:

```
sargon_learning.sqlite
```

con:

```
learned_weights
piece_context
depth_model
```

y estadísticas:

```
source
samples
wins
losses
draws
confidence
last_update
```

Además:

```
model_version
created
games_seen
expert_games_seen
```

Esto permite auditoría y rollback.

14. Interfaz de línea de comandos

Una interfaz posible:

```
sargon --learn-game
sargon --learn-pgn masters.pgn
sargon --learn-pgn masters.pgn --authority 5

sargon --learning off
sargon --learning weights
sargon --learning pieces
sargon --learning full
```

15. Métricas obligatorias

Deben conservarse simultáneamente:

$$V_S(s)$$

y:

$$V_L(s).$$

Además:

```
move_baseline
move_learned
```

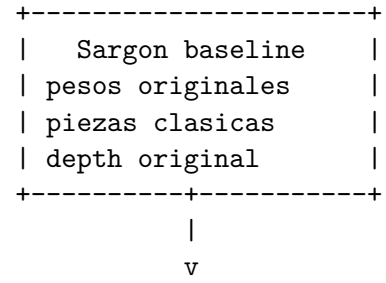
Una métrica importante es:

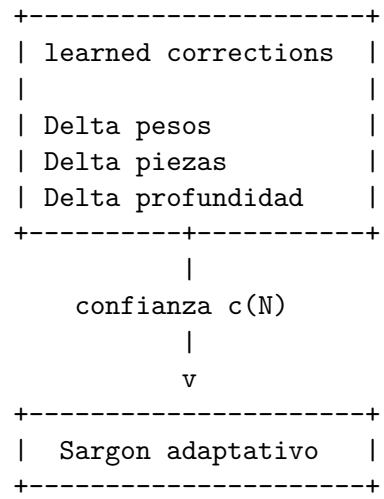
$$P\left(a_{\text{learned}} \neq a_{\text{Sargon}}\right).$$

También deben medirse:

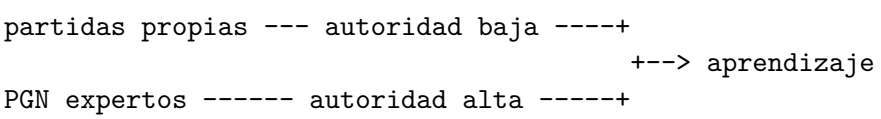
- coincidencia con jugadas expertas;
- error de valoración;
- estabilidad de pesos;
- variación por fuente;
- profundidad media;
- nodos buscados;
- resultados de partidas;
- diferencia entre evaluación clásica y aprendida.

16. Arquitectura resumida





Fuentes:



La integración conceptual:

$$\boxed{\theta_{\text{eff}} = (1-c)\theta_{\text{Sargon}} + c\theta_{\text{learned}}}$$

con:

$$c(0) = 0.$$

17. Plan experimental recomendado

La primera implementación debería limitarse al aprendizaje de pesos de evaluación.
La persistencia, sin embargo, debe diseñarse desde el comienzo para admitir:

- `piece_context`;
- `depth_model`.

Antes de avanzar al segundo nivel deberían demostrarse:

$$\text{PGN experto} \rightarrow \text{cambio estable de pesos},$$

$$\text{más experiencia} \rightarrow \text{mayor confianza},$$

y:

$$\text{pesos aprendidos} \rightarrow \text{mejor coincidencia con decisiones expertas}.$$

Sólo entonces debería incorporarse el valor contextual de las piezas.
La profundidad adaptativa debe ser la tercera etapa porque no sólo incorpora conocimiento ajedrecístico, sino también una decisión sobre cuánto recurso computacional asignar.

18. Conclusión

La propuesta organiza la evolución de Sargon alrededor de tres capacidades:

1. aprender cuánto pesan los factores posicionales;
2. aprender cuánto vale una pieza según el contexto;
3. aprender cuánto análisis merece una posición.

Las tres comparten una propiedad esencial:

$$\boxed{\text{experiencia cero} \Rightarrow \text{Sargon clásico}}$$

y sólo modifican el comportamiento cuando existe evidencia suficiente.

Esto permite construir un Sargon progresivamente adaptativo manteniendo interpretabilidad, control experimental, posibilidad de rollback y separación clara entre conocimiento original y conocimiento aprendido.